

# 染色体微缺失疾病 · 计算验证通路复盘报告

项目：iGEM「RNA binder 剂量补偿治疗染色体微缺失病」的干实验（计算）部分 日期：2026-08-18  
| 作者：船行渔歌（AI 辅助：Hermes Agent）

## 0. 术语表（本报告用到的所有专业术语）

| 术语                        | 通俗含义                                             |
|---------------------------|--------------------------------------------------|
| 转录因子 (TF)                 | “开关型”基因：它的蛋白能结合 DNA，去激活/抑制别的基因。像”总开关”            |
| 归因 (attribution)          | 用可解释 AI 算出”每个基因对细胞身份有多重要”的分数                     |
| 差异归因                      | 疾病细胞 vs 健康细胞的归因之差，看哪些基因的”重要性”在疾病里变了              |
| Integrated Gradients (IG) | 一种归因算法（沿”全零→真实输入”的路径积分梯度）                        |
| SCimilarity               | Genentech 的单细胞基础模型（2300 万细胞预训练），把细胞表达编码成 128 维嵌入 |
| SIGnature                 | Genentech 的归因框架，给 SCimilarity 等模型算每个基因的重要性       |
| 单细胞基础模型 (FM)              | 在超大单细胞数据上预训练的神经网络，学到的嵌入能代表细胞状态                   |
| CellOracle                | 用基因调控网络 (GRN) 做”计算机内基因扰动”的工具                     |
| 基因调控网络 (GRN)              | “TF → 靶基因”的有向调控关系图（谁控制谁）                         |
| 单倍不足 (haploinsufficiency) | 两个等位基因丢了一个，剩下 50% 剂量不够用而致病                       |
| 剂量补偿                      | 把剩下的等位基因上调（转录或翻译），补回接近 100% 剂量                   |
| 主效基因                      | 一个病里起主要致病作用的基因（相对”乘客基因”而言）                       |
| motif                     | TF 结合 DNA 的短序列模式（用于推断 TF 调控关系）                   |
| 差异表达 (DE)                 | 疾病 vs 健康的基因表达差异（最经典的找差异基因方法）                     |
| 单遍编码器                     | 只做”输入→嵌入”一次前向的模型，无法预测下游变化（无级联）                   |

| 术语                  | 通俗含义                                    |
|---------------------|-----------------------------------------|
| 转录层 / 翻译层           | 基因表达的两个层次：转录产生 mRNA，翻译产生蛋白              |
| RNA binder / SINEUP | 结合 RNA 特定区域、上调其翻译的元件（ <b>本项目的药物机制</b> ） |
| 反事实扰动               | “如果把这个基因改掉，细胞会怎样”的模拟                    |
| 级联（cascade）         | 扰动一个基因后，效应经调控网络逐层传播到下游                  |
| 域迁移（domain shift）   | 模型训练数据与应用数据分布不同（如：癌细胞系 → 脑组织）           |
| 零样本外推               | 模型对没见过的基因/组织做预测                         |
| 类器官（organoid）       | 干细胞分化成的微型组织（本报告用脑类器官）                   |
| iPSC                | 诱导多能干细胞                                 |
| HVG（高变基因）           | 表达变化最大的基因，用于降维/聚类                       |

## 1. 项目背景与目标

**疾病：**染色体微缺失病（22q11.2DS、Williams、Angelman 等）——一大段染色体丢失，段里 20~40 个基因同时”单倍不足”（剂量减半）。

**药物：**RNA binder（SINEUP 式）——结合目标基因 RNA 的特定区域，**上调其翻译**，把剩下的等位基因补回 100% 剂量（剂量补偿）。

**本报告的目标：**走通一条计算通路——**确定疾病 → 确定细胞类型 → 患者单细胞数据归因 → 候选基因列表 → 模拟扰动后状态验证**——并诚实记录每一步的问题、思路、方法、结果与不足。

## 2. 通路五步（逐环节复盘）

### 第 1 步：确定疾病

- **【问题】** ① 扰动工具 CellOracle 只能扰动 TF；② 微缺失病是多基因缺失、关键基因多数**不是 TF**；③ 人类微缺失病 scRNA 数据集中在脑类器官。
- **【思路】** 选一个”关键基因是 TF 且在数据里有表达”的病。
- **【方法】** 初选 22q11.2DS + TBX1（TF）→ 实测 TBX1 在脑里不表达 → **pivot 到 Williams + GTF2I**（脑表达 TF）。

- **【结果】** 22q11.2DS 脑数据无法扰动 (TBX1 仅 15/9293 细胞); Williams + GTF2I 可行 (GTF2I 表达于 82% 细胞)。
- **【不足】** 只做了 Williams 一个病 (原计划 2+ 病); 未覆盖“单一主效基因”型病 (Angelman/UBE3A、Smith–Magenis/RAI1); 工具对非 TF 关键基因适用面窄。

## 第 2 步：确定细胞类型

- **【问题】** 脑类器官是**多细胞类型混杂** (16 个 cluster), 非单一细胞类型; 缺细胞类型注释。
- **【思路】** 聚类后按 cluster 分别建 GRN; 分析时做疾病 vs 对照的整体对比。
- **【方法】** 6 样本合并 (96969 细胞) → QC → 归一化 → HVG (3000) + 强制保留 Williams 区段基因 → PCA/UMAP/Leiden 聚类 (16 cluster)。
- **【结果】** 96969 细胞 × 3016 基因, 16 cluster, GTF2I 确认高表达。
- **【不足】** **未注释具体细胞类型** (哪种神经元/前体); 疾病 DE 是混合细胞类型的 bulk 对比, 可能被“细胞类型组成差异”污染; 未聚焦 GTF2I 最相关的细胞亚群。

## 第 3 步：患者单细胞数据归因

- **【问题】** SCimilarity 是单遍编码器 (无级联); **归因 ≈ 表达** (机械冗余); 归因 ≠ 因果 (实测  $r=0.02$ ); 预测性测试证实**归因无独立预测力**。
- **【思路】** 用归因看“疾病里哪些基因的重要性变了”, 作为候选来源。
- **【方法】** SIGnature + SCimilarity + IG 归因 (5000 患者 + 5000 对照) → 差异归因 (WS – CTRL)。
- **【结果】** 差异归因 ≈ 差异表达 ( $r=0.949$ ); 疾病信号 = 神经元分化基因 (NEUROD2/6、SOX5、NFIA 等); **删失基因自身归因≈0 变化**。
- **【不足】** 归因只给“重要性排序”, 不给因果、不给方向, 且基本是差异表达的镜像、无独立信息。

## 第 4 步：候选基因列表

- **【问题】** 归因给出的候选是“下游受影响程序”, 不是“可扰动靶点”; 候选多数不是 TF, 无法用 CellOracle 验证。
- **【思路】** 从差异归因/差异表达提取候选, 并与 CellOracle 结果交叉比对。
- **【方法】** 取  $|\Delta\text{归因}|$  最大的基因 + CellOracle“被过表达拉回”的 top 基因, 求交集。
- **【结果】** 候选 = 神经元分化程序 (NEUROD2/6、SOX5、NFIA、ZEB2、BCL11B...); **CellOracle 与 SIGnature 两个独立方法收敛到同一批基因** (交叉验证, 本通路最硬的结果)。
- **【不足】** 候选未经过“可成药/可扰动”筛选; 候选基因与“治疗靶点”之间的**因果链未建立**。

## 第 5 步：模拟扰动后状态验证

- **【问题】** ① CellOracle 只能扰 TF, 候选多数不是 TF; ② **单基因扰动 vs 多基因缺失不匹配**; ③ 删失基因自身  $DE \approx 0$ , 扰动效应弱。
- **【思路】** 用 GTF2I (文献公认的脑表型主效基因) 做敲低/过表达, 看能否复现/逆转疾病转录组。

- **【方法】** CellOracle GRN (预构建 hg38 promoter base GRN) → `fit_GRN_for_simulation` → `simulate_shift` (GTF2I 敲低→0、过表达→2×)。
  - **【结果】** GTF2I 敲低  $r=-0.046$ 、过表达  $r=+0.072$  (都  $\approx 0$ , 无系统信号); 但 top 被恢复基因方向对 (SOX5/NEUROD2/NFIA 等神经基因被过表达往上拉)。
  - **【不足】** 单基因扰动抓不到整个多基因缺失的转录组; 无法扰动非 TF 基因 (GTF2IRD1/ELN/LIMK1...)。
- 

### 3. 贯穿全程的三个根本不足

---

1. **翻译层盲区 (最致命)**: 本项目药物是 RNA binder (蛋白层上调), 而所有 mRNA 模型 (SCimilarity/CellOracle/GEARS) 都假设“mRNA↔蛋白耦合成立”——药物恰好人为打破这层耦合, **归因和扰动都打在错误的一层**, 模型从结构上看不见药效。
  2. **单基因 vs 多基因错配**: 微缺失病是多基因剂量敏感, 而归因排序 + 单基因 TF 扰动都是单基因视角, 只能抓到疾病信号的零头。
  3. **删失基因稳态 mRNA 层面“隐身”**: 实测删失基因 (GTF2I 等) 的表达和重要性在患者里几乎不变 ( $DE \approx 0$ 、 $\Delta$ 归因  $\approx 0$ ) ——单倍不足效应在稳态 mRNA 上测不到, 整条“从 mRNA 数据找靶点”的路都有天花板。
- 

### 4. 结论与建议

---

**结论**: 这条通路在“转录层、单一主效 TF、有表达、单一细胞类型”的理想条件下是通顺的 (归因→候选→扰动验证, 且两工具能交叉收敛); 但在本项目真实条件 (翻译层 RNA binder + 多基因单倍不足 + 非 TF 关键基因 + 混合脑类器官) 下, 每一步都撞上结构性天花板。

**最硬的正面资产**: 候选基因列表 (神经元分化程序: NEUROD2/6、SOX5、NFIA、ZEB2、BCL11B) 被两个独立工具交叉验证——可作为 iGEM 干实验结论, 但须诚实标注它只是“相关/候选”, 不是“因果/可成药靶点”。

**建议**: – 选病优先“单一主效 + 脑表型 + 剂量敏感” (如 Angelman/UBE3A、Smith–Magenis/RAI1)。– 若坚持 mRNA 工具, 须明确“转录层补偿  $\approx$  翻译层补偿”的假设, 并注明 G 自身 mRNA 读数是盲区。– 翻译层药效的最终验证, 仍需蛋白组/湿实验, mRNA 工具只能做“候选生成”。